

Plataforma Inteligente para Apoio à Decisão em Segurança Viária

Jean C. C. Gondorek¹, Henrique R. Rodrigues¹

¹ Universidade Federal da Fronteira Sul (UFFS) – Chapecó, SC – Brasil

jean.gondorek@estudante.uffs.edu.br, henrique.ribeiro@uffs.edu.br

Abstract. *This paper presents a decision-support platform for road safety on the federal highways of Santa Catarina, a state with strategic road corridors and one of the highest crash rates in Brazil. The proposal uses open microdata on traffic accidents provided by the Federal Highway Police (2020-2025) to train supervised machine learning models capable of predicting accident severity, together with spatial clustering algorithms (DBSCAN/HDBSCAN) to identify critical crash hotspots along the highways. Results will be delivered through an interactive dashboard with heat maps, temporal filters, and risk simulators to support enforcement and public safety planning. The tool is expected to shift current reactive management toward a predictive approach, optimizing the allocation of public resources and helping reduce fatalities and serious injuries on Santa Catarina's highways.*

Resumo. *Este artigo apresenta uma proposta de plataforma de apoio à decisão para segurança viária nas rodovias federais de Santa Catarina, estado que concentra eixos rodoviários estratégicos e um dos maiores índices de sinistralidade do país. A proposta utiliza os microdados abertos de acidentes disponibilizados pela Polícia Rodoviária Federal (2020-2025) para treinar modelos de aprendizado de máquina supervisionado capazes de prever a severidade de acidentes, além de algoritmos de clusterização espacial para identificar manchas críticas de sinistralidade ao longo das rodovias. Os resultados serão disponibilizados por meio de um dashboard interativo com mapas de calor, filtros temporais e simuladores de risco, destinado a apoiar gestores da fiscalização e do planejamento operacional de segurança pública. O objetivo é que a ferramenta permita substituir a gestão reativa atual por uma abordagem preditiva, otimizando a alocação de recursos e contribuindo para a redução de mortes e feridos nas rodovias catarinenses.*

1. Introdução

A malha rodoviária é um dos principais meios de locomoção de mercadorias e passageiros no Brasil, sendo responsável por mais de 60 % das mercadorias e 90 % do tráfego de passageiros (CNT, 2023). Porém, os índices de sinistros nessa modalidade são extremamente elevados. Segundo a Organização Mundial da Saúde (OMS, 2023), os acidentes de trânsito estão entre os principais causadores de mortes evitáveis no mundo, custando elevadas cifras em infraestrutura e saúde pública dos países em desenvolvimento.

O estado de Santa Catarina possui uma malha federal estratégica e de alta complexidade. Ela conecta diversos polos industriais, agroindustriais e turísticos do estado aos maiores complexos portuários do país e às fronteiras internacionais (SEPLAN-SC, 2021). Em destaque temos eixos vitais como a BR-101 (corredor litorâneo de alta densidade de tráfego), a BR-282 (que cruza o estado do Litoral ao Extremo-Oeste), a BR-470 (principal rota do Vale do Itajaí) e a BR-116 (ligação de longa distância no Planalto Catarinense), além de rodovias de integração regional como as BRs 153, 158, 163, 280, 285 e 480 (DNIT, 2009).

Somado a isso, o estado combina diversos tipos de topografias acentuadas, trechos urbanizados com sobreposição de tráfego local e de longa distância, intenso fluxo de veículos pesados e severas variações meteorológicas, como neblina e chuvas intensas (DNIT, 2009). Tais características tornam a malha rodoviária catarinense historicamente uma das mais violentas do país em estatísticas de sinistros (BRASIL, 2024).

Atualmente, a PRF disponibiliza, por meio de portal de dados abertos do Governo Federal, um extenso acervo histórico detalhado de ocorrências de acidentes de trânsito (BRASIL, 2024). Esses microdados contêm variáveis ricas de georreferenciamento (latitude, longitude, km e rodovia), características temporais e severidade dos sinistros em todos os municípios catarinenses.

Apesar da expressiva disponibilidade e alta granularidade dos dados abertos mantidos pela PRF, a gestão de segurança viária e a alocação de recursos operacionais de fiscalização e socorro ainda ocorrem, predominantemente de forma reativa baseada em estatísticas agregadas a *posteriori*.

Análises estáticas tradicionais possuem limitações metodológicas para mapear interações não lineares entre o histórico de acidentes e sua gravidade em trechos específicos. A ausência de modelos preditivos e geoespaciais integrados impede gestores operacionais da PRF e de órgãos estaduais anteciparem pontos de alto risco sob diferentes cenários dinâmicos.

Diante disso, se define a seguinte questão de pesquisa: Como algoritmos de *Machine Learning* e técnicas de análise geoespacial podem ser aplicadas sobre os microdados de acidentes da PRF para mapear manchas críticas de sinistralidade e prever gravidade de acidentes nas rodovias federais de Santa Catarina?

Nesse cenário, a proposta de desenvolvimento de uma plataforma de apoio à decisão de segurança viária baseada em modelos de *Machine Learning* e *dashboards* interativos se mostra essencial, visto a necessidade de uma visualização assertiva e com contexto dos dados abertos de acidentes disponibilizados pela PRF para mapear trechos críticos e prever gravidade de sinistros nas rodovias federais do estado de Santa Catarina.

Em vista desse planejamento, o projeto apoia-se em três pilares principais: social e humano, econômico, científico e tecnológico. No âmbito social e humano, os acidentes de trânsito causam impactos sociais profundos e perdas irreparáveis de vidas (IPEA, 2015). Nesse sentido, a aplicação de modelos preditivos permite a alocação preventiva do patrulhamento, reduzindo diretamente a taxa de mortes e feridos graves.

No âmbito econômico, estima-se que os acidentes em rodovias federais geram custos anuais à sociedade superiores a R\$12 bilhões, englobando gastos com saúde pública, previdência e perda de produtividade (IPEA, 2020). Assim, a identificação precisa de pontos críticos otimiza os recursos públicos investidos em engenharia e fiscalização.

Por fim, contribui rodovias a partir da integra bases de dados abertas governamentais com técnicas de *Machine Learning* e inteligência geográfica, alinhando-se aos conceitos de Governo Orientado a Dados (Data-Driven Government).

2. Trabalhos Relacionados

Diversos estudos têm abordado a aplicação das tecnologias da informação na análise de acidentes de trânsito em rodovias brasileiras, com foco em soluções de visualização de dados e modelagem preditiva.

Nunes, Nascimento e Rocha (2020) introduzem o DASHCARE, um painel de controle desenvolvido com tecnologias Web e um banco de dados NoSQL, voltado para o acompanhamento dos dados abertos da PRF.

Com foco na dimensão geográfica, Mattos et al. (2019) desenvolveram um protótipo de visualização dos dados da PRF utilizando sistemas de informação geográfica (PostGIS e Leaflet). A solução agrupa dinamicamente os acidentes no mapa do Brasil (com ênfase na região Sul) para mitigar o problema de sobreposição visual de ocorrências e facilitar a identificação de padrões. Contudo, a abordagem limita-se à análise descritiva e espacial histórica.

Já referente à inteligência artificial aplicada à segurança viária, Malaquias et al. (2021) utilizaram técnicas de *Machine Learning* sobre os dados da PRF para classificar as causas de acidentes rodoviários. Os autores aplicaram algoritmos como Random Forest, Regressão Logística e Máquina de Vetores de Suporte, demonstrando que o aprendizado de máquina é capaz de identificar padrões de risco. Porém, o estudo tem caráter analítico e não propõe a integração do modelo a uma plataforma geoespacial dinâmica para uso operacional continuado.

Diferente dos trabalhos citados, a proposta deste artigo unifica as três frentes tecnológicas para suprir a lacuna de ferramentas dinâmicas na gestão pública. O trabalho aplica o uso dos microdados da PRF em um *pipeline* automatizado, através de algoritmos de *Machine Learning* para prever a severidade das ocorrências e utiliza técnicas de clusterização espacial (HDBSCAN/DBSCAN) para delimitar *hotspots*, entregando os resultados em um único *dashboard* interativo voltado ao planejamento tático e operacional.

Tabela 1. Comparativo entre a plataforma proposta e os trabalhos relacionados.

Trabalho Relacionado	Base de Dados	Foco Principal	Predição (ML)	Clusterização Espacial	Dashboard Interativo
NUNES et al.	PRF (Brasil)	Estruturação de dados (ETL) e estatísticas descritivas nacionais	Não	Não	Sim
MATTOS et al.	PRF (Brasil)	Visualização geográfica descritiva e mitigação de sobreposição visual	Não	Sim	Sim

MALAQUIAS et al.	PRF (Brasil)	Classificação de causas de acidentes com Random Forest	Sim	Não	Não
Proposta Atual	PRF (SC)	Plataforma integrada preditiva e geoespacial para apoio à decisão	Sim	Sim	Sim

3. Referencial Teórico

Esta seção apresenta os fundamentos teóricos e as ferramentas computacionais que sustentam a proposta metodológica deste trabalho. São abordados três eixos: o Aprendizado de Máquina Supervisionado, aplicado à classificação da severidade dos sinistros; a Clusterização Espacial baseada em densidade, empregada na identificação de zonas críticas de acidentes; e a Inteligência de Negócios, utilizada na etapa final de consolidação e apresentação dos resultados. A ordem de exposição segue o fluxo de tratamento dos dados adotado na proposta: da predição individual do sinistro, passando pela identificação de padrões espaciais, até a entrega de insights ao usuário final.

3.1 Aprendizado de Máquina Supervisionado

O Aprendizado de Máquina Supervisionado é um paradigma no qual um modelo é treinado a partir de um conjunto de dados rotulados, dessa forma cada amostra possui uma variável-alvo (*label*) conhecida previamente. Durante o treinamento, o algoritmo ajusta seus parâmetros internos de modo a minimizar o erro entre a predição gerada e o rótulo real, generalizando esse padrão para dados não vistos posteriormente (JAMES *et al.*, 2013).

Com base nos trabalhos relacionados, o artigo discute, dentro do contexto de rodovias brasileiras e a mineração de dados extraídos desses trechos, como os algoritmos de Aprendizado de Máquina Supervisionado têm sido essenciais na leitura desses dados. O foco principal em classificação (escrever quais classificações) influenciam em sinistros no trânsito. Isso cria desafios sobre como fazer uso dessas informações já filtradas para trazer mais segurança e melhor sinalização aos condutores.

Dentro desse paradigma, a tarefa de classificação consiste em atribuir a cada amostra uma categoria discreta pertencente a um conjunto finito de classes. Neste trabalho, a variável-alvo corresponde à severidade do sinistro de trânsito, categorizada em três classes: *sem vítimas*, *com feridos* e *com vítimas fatais*. Trata-se, portanto, de um problema de classificação multiclasse, no qual o modelo deve aprender, a partir de variáveis como condições da via, horário, tipo de veículo e características do traçado, a relação entre esses atributos e o desfecho do sinistro.

3.2 Clusterização Espacial (Densidade)

Diferentemente do aprendizado supervisionado, o Aprendizado Não Supervisionado trabalha com dados sem rótulo prévio, buscando identificar estruturas, padrões ou agrupamentos (*clusters*) inerentes aos próprios dados. Em decorrência disso,

os algoritmos de clusterização baseada em densidade agrupam pontos que estão próximos entre si em regiões de alta concentração. Estas delimitações são fundamentais, também, para eliminar acidentes isolados e identificar manchas irregulares no diagrama ou gráfico. A proposta do artigo é realizar um estudo com uso desse material gerado para apresentar índices e números delimitados por zonas e coordenadas geográficas.

De maneira assertiva, o modelo DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) forma clusters a partir de dois parâmetros: o raio de vizinhança ϵ (epsilon) e o número mínimo de pontos necessários para que uma região seja considerada densa. Pontos que não atendem a esse critério de densidade em relação a nenhum cluster são classificados como ruído (*noise*) (ESTER *et al.*, 1996). Além disso, o HDBSCAN (*Hierarchical DBSCAN*) estende esse conceito ao construir uma hierarquia de agrupamentos em diferentes níveis de densidade, dispensando a definição manual de ϵ e tornando o modelo mais robusto a bases de dados com densidade variável entre regiões (CAMPELLO; MOULAVI; SANDER, 2013).

Ao contrário de métodos que assumem clusters de formato esférico, os algoritmos baseados em densidade identificam agrupamentos de formato irregular, ideais para zonas como faixas de rodovia com alta concentração de acidentes que identificam ocorrências isoladas como ruído, evitando que sinistros pontuais e não representativos distorçam a identificação de zonas críticas (os chamados *pontos negros* ou *black spots*).

3.3 Inteligência de Negócios (BI)

A Inteligência de Negócios (*Business Intelligence - BI*) compreende o conjunto de processos, tecnologias e ferramentas voltados à coleta, ao tratamento e à apresentação de dados para subsidiar a tomada de decisão (TURBAN *et al.*, 2009). A construção de dashboards analíticos, que possuem interface visual que consolida indicadores, gráficos e mapas de forma sintética, depende do processo de ETL (*Extract, Transform, Load*), responsável por extrair os dados brutos da tabela e transformá-los em *insights* que evidenciam os agrupamento de sinistros. Esse processo permite que órgãos públicos de gestão viária utilizem dados historicamente dispersos para gerar provas que orientem políticas de segurança viária, priorização de sinalização e intervenções em trechos críticos.

4. Metodologia: Design Science Research Methodology (DSRM)

A presente pesquisa adota como metodologia a *Design Science Research Methodology* (DSRM), proposta por Peffers *et al.* (2007), que é constantemente implementada a fim de orientar o desenvolvimento de uma solução de Machine Learning aplicada à segurança pública. O modelo organiza o processo de pesquisa em seis etapas sequenciais, as quais são: problema e motivação, definição dos objetivos da solução, projeto e desenvolvimento, demonstração, avaliação e comunicação.

O projeto utiliza o GitHub como ambiente central para versionamento do código, documentação, organização das atividades e armazenamento do artigo científico. O Google Colab é utilizado para exploração dos dados, pré-processamento, experimentação e treinamento dos modelos, enquanto o Streamlit Community Cloud é utilizado para disponibilização da aplicação ao usuário final.

Para alcançar o objetivo geral proposto, este trabalho está estruturado em quatro etapas complementares. Inicialmente, será construído um *pipeline* de ETL espaço-temporal, responsável por coletar, higienizar e estruturar as bases de dados de acidentes da PRF referentes ao período de 2020 a 2025, filtrando e padronizando os registros georreferenciados de todas as rodovias federais de Santa Catarina.

Em seguida, serão desenvolvidos modelos preditivos de aprendizado de máquina, por meio do treinamento e da avaliação de algoritmos supervisionados como XGBoost, Random Forest e LightGBM, com o objetivo de prever e classificar a severidade dos acidentes nas categorias sem vítimas, com feridos e fatais.

Na sequência, será realizado o mapeamento de agrupamentos geoespaciais (*hotspots*), por meio da aplicação de algoritmos de *clustering* como DBSCAN ou HDBSCAN, permitindo delimitar dinamicamente as manchas de sinistralidade ao longo dos quilômetros das rodovias do estado. Por fim, será implementado um *dashboard* interativo, composto por mapas de calor, filtros temporais e simuladores de risco, capaz de apoiar a tomada de decisão no planejamento operacional de segurança pública.

4.1 Identificação do Problema e Motivação

Esta etapa corresponde ao problema de pesquisa apresentado e evidenciado pela ausência de modelos preditivos e geoespaciais integrados, capazes de antecipar pontos de alto risco sob diferentes cenários dinâmicos e de como a gestão da segurança viária nas rodovias federais de Santa Catarina ocorre de forma predominantemente reativa, baseada em estatísticas agregadas *a posteriori*, apesar da ampla disponibilidade e granularidade dos microdados abertos fornecidos pela PRF.

Essa lacuna também é reforçada pela análise dos trabalhos relacionados (Seção 2), que tratam de forma isolada a estruturação de dados, a visualização geográfica descritiva ou a classificação da severidade dos sinistros, sem integrar essas frentes em uma única ferramenta operacional.

4.2 Definição dos Objetivos da Solução

A partir do problema identificado, definem-se como objetivos da solução: (i) prever a severidade dos acidentes de trânsito, classificando-os nas categorias sem vítimas, com feridos e fatal; (ii) identificar, por meio de algoritmos de clusterização espacial, as manchas críticas (*hotspots*) de sinistralidade ao longo das rodovias federais catarinenses; e (iii) disponibilizar esses resultados de forma acessível a gestores públicos, por meio de um *dashboard* interativo com mapas de calor, filtros temporais e simuladores de risco, permitindo substituir a gestão reativa atual por uma abordagem preditiva de alocação de recursos.

4.3 Projeto e Desenvolvimento

O projeto utiliza o GitHub como ambiente central para versionamento do código, documentação, organização das atividades e armazenamento do artigo científico. O Google Colab é utilizado para exploração dos dados, pré-processamento, experimentação e treinamento dos modelos, enquanto o Streamlit Community Cloud é utilizado para disponibilização da aplicação ao usuário final.

4.3.1 Coleta e processamento dos dados

Os dados são obtidos a partir do Portal de Dados Abertos da PRF, considerando registros de acidentes ocorridos em rodovias federais de Santa Catarina no período de 2020 a 2025.

Para evitar *data leakage*, são removidas de forma estrita as variáveis coletadas apenas após a ocorrência do sinistro (como a contagem de mortos, feridos graves e ileso), garantindo que o modelo utilize exclusivamente atributos preditivos disponíveis no momento do risco.

Inicialmente, os dados são submetidos a uma análise exploratória para identificar valores ausentes, inconsistências, distribuição das variáveis e características relevantes para a modelagem. Em seguida, são realizadas etapas de limpeza e padronização dos dados, incluindo o tratamento de registros com informações geográficas ausentes ou inconsistentes e a seleção das variáveis relevantes para o problema.

Também são criadas variáveis derivadas relacionadas ao contexto temporal e espacial dos acidentes, como *periodo_do_dia* (madrugada, manhã, tarde e noite), *dia_da_semana*, *eh_fim_de_semana*, *mes* e *eh_feriado*. Os atributos numéricos (km, latitude e longitude) têm seus valores ausentes imputados pela mediana e são padronizados por meio de *StandardScaler*, enquanto os atributos categóricos (*br*, *fase_dia*, *condicao_meteorologica*, *tipo_pista*, *tracado_via* e *tipo_acidente*) são codificados via *OneHotEncoder*, integrados em um único pipeline por meio de um *ColumnTransformer* do Scikit-Learn.

A variável-alvo utilizada na predição representa a severidade do acidente, dividida em três classes:

- Classe 0: acidente sem vítimas;
- Classe 1: acidente com feridos;
- Classe 2: acidente fatal.

4.3.2 Modelagem e avaliação técnica dos algoritmos

Após o processamento, os dados são divididos em conjuntos de treinamento e teste, utilizando 80% dos registros para treinamento e 20% para avaliação, com amostragem estratificada em relação à variável-alvo, dado o severo desbalanceamento entre as classes de gravidade.

Foram avaliados e comparados três algoritmos de aprendizado de máquina supervisionado para a tarefa de classificação multiclasse: Random Forest, XGBoost e LightGBM, permitindo verificar qual modelo apresenta o desempenho mais adequado ao problema.

Devido ao desbalanceamento das ocorrências, com proporção muito baixa de acidentes fatais, a métrica norteadora principal adotada é o F1-Score ponderado (weighted), complementada por acurácia, precisão (precision), revocação (recall), matriz de confusão e ROC-AUC no esquema um-contra-todos (One-vs-Rest).

Após a avaliação, o modelo de melhor desempenho é treinado e serializado (*baseline_model.joblib*) para posterior utilização pela aplicação, sendo armazenado e versionado no repositório do projeto no GitHub, o que permite sua reutilização sem a necessidade de realizar novamente o treinamento. O pipeline de pré-processamento e

modelagem é documentado no notebook *notebooks/02_preprocessing_modeling.ipynb*, e uma função de carregamento automatizado realiza o download do conjunto de dados diretamente da URL Raw do repositório, garantindo a execução autônoma e reproduzível do experimento no Google Colab.

4.3.3 Desenvolvimento da aplicação

A aplicação é desenvolvida utilizando Streamlit, permitindo ao usuário informar as características de um acidente e obter a classificação de severidade estimada pelo modelo.

A interface é projetada priorizando simplicidade, clareza e apresentação visual dos resultados. Além da integração com o modelo preditivo, são realizados testes das principais funcionalidades da aplicação.

O código-fonte, notebooks, dados processados, modelo treinado, testes e documentação são versionados no GitHub, seguindo a estrutura definida para o projeto.

4.4 Demonstração

Após a integração e validação, a aplicação é publicada no Streamlit Community Cloud, disponibilizando o sistema para utilização por usuários finais. Essa disponibilização constitui a demonstração do artefato em um cenário real, utilizando os microdados de acidentes das rodovias federais de Santa Catarina para evidenciar sua capacidade de estimar a severidade dos sinistros e de apoiar a tomada de decisão de gestores da fiscalização e do planejamento operacional de segurança pública.

4.4 Avaliação e Evolução da Solução

Após a disponibilização do MVP, são analisados os resultados obtidos pelo modelo e o funcionamento da aplicação, considerando também feedbacks relacionados à utilização e à apresentação das informações.

Com base nessa avaliação, são realizadas melhorias no modelo, na interface ou no fluxo da aplicação quando necessário. O desenvolvimento ocorre de forma incremental, mantendo o código, os experimentos, a documentação e o artigo científico atualizados ao longo do projeto.

Ao final, são consolidados os resultados experimentais, as limitações identificadas e as possibilidades de evolução da solução, buscando manter a correspondência entre o sistema implementado, os experimentos realizados e o conteúdo apresentado no artigo.

4.5 Avaliação

A análise de importância das variáveis e da matriz de confusão do modelo baseline indica que a dimensão geográfica (longitude, km e latitude) é o fator mais determinante da severidade, uma vez que as coordenadas concentram implicitamente características viárias e topográficas fixas, como declives, ausência de mureta e trechos urbanizados.

O modelo também evidencia uma disparidade regional entre o Oeste e o Litoral catarinense: o risco e a severidade tendem a aumentar à medida que a longitude

decrece em direção ao Oeste, onde rodovias de pista simples (como as BRs 282, 153 e 480), associadas ao intenso tráfego de veículos de carga da agroindústria e à escassez de duplicações, apresentam maior proporção de colisões frontais de alta letalidade. Observa-se ainda que os períodos de madrugada e finais de semana elevam o risco de sinistros fatais, em razão da combinação de fadiga, velocidade e visibilidade reduzida.

O peso identificado para a dimensão geográfica reforça diretamente a relevância da aplicação de algoritmos de clusterização espacial (DBSCAN/HDBSCAN) e a construção de mapas de calor no dashboard interativo, previstos para a próxima iteração do projeto.

Após a disponibilização do MVP, são analisados os resultados obtidos pelo modelo e o funcionamento da aplicação, considerando também feedbacks relacionados à utilização e à apresentação das informações.

Com base nessa avaliação, são realizadas melhorias no modelo, na interface ou no fluxo da aplicação quando necessário, retornando-se às etapas de projeto e desenvolvimento sempre que preciso. O desenvolvimento ocorre, assim, de forma incremental, mantendo o código, os experimentos, a documentação e o artigo científico atualizados ao longo do projeto.

Ao final, são consolidados os resultados experimentais, as limitações identificadas e as possibilidades de evolução da solução, buscando manter a correspondência entre o sistema implementado, os experimentos realizados e o conteúdo apresentado no artigo.

4.6 Comunicação

A comunicação dos resultados desta pesquisa ocorre por meio da produção deste artigo científico, do repositório público mantido no GitHub, que reúne código-fonte, notebooks, dados processados, modelo treinado e documentação da disponibilização da aplicação no Streamlit Community Cloud. Dessa forma, gestores públicos, pesquisadores e demais interessados têm acesso tanto ao artefato desenvolvido quanto ao processo metodológico que fundamentou sua construção.

Declaração de uso de inteligência artificial

Durante a elaboração deste trabalho, ferramentas de inteligência artificial generativa foram utilizadas como apoio à revisão linguística, organização textual e tradução de trechos. O conteúdo produzido com auxílio dessas ferramentas foi revisado e validado pelos autores, que permanecem integralmente responsáveis pela precisão, integridade e conteúdo final do trabalho.

Referências

BRASIL. Polícia Rodoviária Federal (PRF). Dados Abertos da PRF: Acidentes e Infrações. Brasília: Ministério da Justiça e Segurança Pública, 2024. Disponível em: <https://www.gov.br/prf/pt-br/aceso-a-informacao/dados-abertos>. Acesso em: 9 ago. 2026.

CARVALHO, Carlos Henrique Ribeiro de. Custos dos acidentes de trânsito no Brasil: estimativa simplificada com base na atualização das pesquisas do Ipea sobre custos de acidentes nos aglomerados urbanos e rodovias. Brasília: Ipea, 2020. (Texto para Discussão, n. 2565). Disponível em: <https://repositorio.ipea.gov.br/server/api/core/bitstreams/06cc1126-53a9-4dae-af80-a7f66708989d/content>. Acesso em: 9 ago. 2026.

CONFEDERAÇÃO NACIONAL DO TRANSPORTE (CNT). *Pesquisa CNT de Rodovias 2023: Relatório Gerencial*. Brasília: CNT, 2023. Disponível em: <https://www.cnt.org.br/agencia-cnt/pesquisa-cnt-de-rodovias-2023-refora-a-importancia-de-maior-investimento-na-malha-rodoviria>. Acesso em: 9 ago. 2026.

DEPARTAMENTO NACIONAL DE INFRAESTRUTURA DE TRANSPORTES (DNIT). *Mapa Multimodal do Estado de Santa Catarina*. Brasília: Ministério dos Transportes, 2009.

INSTITUTO DE PESQUISA ECONÔMICA APLICADA (IPEA). Impactos Econômicos dos Sinistros de Trânsito no Brasil. Brasília: IPEA, 2020. Disponível em (<https://repositorio.ipea.gov.br/server/api/core/bitstreams/5baaae20-8205-4e28-bb6b-b31d3a4d0bc1/content>)

ORGANIZAÇÃO MUNDIAL DA SAÚDE (OMS). Global status report on road safety 2023. Genebra: World Health Organization, 2023. Disponível em: <https://www.who.int/publications/i/item/9789240086517>. Acesso em: 9 ago. 2026.

SECRETARIA DE ESTADO DO PLANEJAMENTO DE SANTA CATARINA (SEPLAN-SC). Plano Estadual de Logística e Transportes de Santa Catarina (PELT-SC). Florianópolis: SEPLAN-SC, 2021.

MALAQUIAS, E. O.; TOSTA, M. C. R.; CHAVES, G. L. D.; RIBEIRO, G. M. (2021). Acidentes em rodovias brasileiras: um estudo com técnicas de machine learning para classificar a causa das ocorrências. In: *Anais do 35º Congresso de Pesquisa e Ensino em Transportes (ANPET)*, p. 2322-2334.

MATTOS, V. G. P.; VASCONCELOS, P. H. V.; PARCIANELLO, Y.; KOZIEVITCH, N. P.; BERARDI, R. (2019). Visualização dos dados abertos da Polícia Rodoviária Federal sobre acidentes nas rodovias brasileiras. In: *Anais do XXXIV Simpósio Brasileiro de Banco de Dados (SBBD)*, 2019, Fortaleza. p. 193-198.

NUNES, F. L. L.; NASCIMENTO, S. M.; ROCHA, A. L. S. (2020). DASHCARE: Um Dashboard para Análise dos Acidentes nas Rodovias Federais. In: *Anais do I Encontro de Computação do Oeste Potiguar (ECOP)*.

JAMES, G. et al. An introduction to statistical learning: with applications in R. New York: Springer, 2013.

ESTER, M. *et al.* A density-based algorithm for discovering clusters in large spatial databases with noise. In: INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING, 2., 1996, Portland. **Anais [...]**. Palo Alto: AAAI Press, 1996. p. 226-231.

CAMPELLO, R. J. G. B.; MOULAVI, D.; SANDER, J. Density-based clustering based on hierarchical density estimates. In: PACIFIC-ASIA CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING, 17., 2013, Gold Coast. **Anais [...]**. Berlin: Springer, 2013. p. 160-172.

TURBAN, E. *et al.* Business intelligence: a managerial approach. 2. ed. Upper Saddle River: Pearson Prentice Hall, 2009.